

Evaluación de la Calidad de Temas: Coherence Score y Perplexity

Tu Nombre

Universidad o Institución

18 de junio de 2026

Contenido

¿Qué es el Coherence Score?

- Métrica para evaluar la calidad semántica de los temas generados por modelos como LDA.
- Mide qué tan coherentes son las palabras asociadas a un tema.
- Cuanto más alto, mejor interpretabilidad del tema.

Tipos de Coherence Scores

- **Umass**: basado en frecuencias conjuntas de pares de palabras.
- **UCI**: usa PMI (Pointwise Mutual Information) sobre ngrams.
- **NPMI**: normalización de PMI para evitar sesgo por frecuencia.
- **Cv** (*el más usado*): combinación intuitiva de varios enfoques.

Fórmula del Coherence C_v

Sea $W = \{w_1, w_2, \dots, w_N\}$ el conjunto de las N palabras más representativas de un tema.

Para cada par $i < j$:

$$s_{C_v}(w_i, w_j) = \frac{\log \left(\frac{D(w_i, w_j) + \epsilon}{D(w_i)} \right)}{-\log \left(\frac{D(w_i)}{|D|} \right)}$$

Donde:

- $D(w_i)$: número de documentos donde aparece w_i
- $D(w_i, w_j)$: documentos donde aparecen ambas palabras
- $|D|$: total de documentos
- ϵ : constante pequeña (ej. 10^{-12})

Coherence Final del Tema

Promedio de similitudes entre todos los pares de palabras:

$$\text{Coherence}_{C_v} = \frac{1}{\binom{N}{2}} \sum_{i < j} s_{C_v}(w_i, w_j)$$

Interpretación:

- Valores cercanos a 1 $\rightarrow$ Temas muy coherentes
- Valores cercanos a 0 o negativos $\rightarrow$ Temas poco interpretables

Ejemplo Numérico

Tema: {"gobierno", "ley", "país", "elecciones", "senado"}

Datos:

- $D = 1000$ documentos
- $D(\text{"gobierno"}) = 200$
- $D(\text{"ley"}) = 150$
- $D(\text{"gobierno", "ley"}) = 100$

Cálculo:

$$s_{C_v}(\text{"gobierno", "ley"}) = \frac{\log(100/200)}{-\log(150/1000)} = \frac{\log(0,5)}{-\log(0,15)} \approx \frac{-0,693}{1,823} \approx -0,38$$

Instalación de paquetes necesarios

```
1 install.packages("topicmodels")
2 install.packages("tm")
3 install.packages("LDavis")
4 install.packages("dplyr")
```


Preprocesamiento básico en R

```
1 library(tm)
2 library(topicmodels)
3
4 # Ejemplo de datos
5 docs <- c(
6   "El gobierno anuncia nuevas leyes",
7   "La ley fue aprobada por el senado",
8   "Elecciones importantes en el pa s",
9   "Los ciudadanos votan en elecciones"
10 )
11
12 # Crear corpus y DTM
13 corpus <- Corpus(VectorSource(docs))
14 corpus <- tm_map(corpus, content_transformer(tolower))
15 corpus <- tm_map(corpus, removePunctuation)
16 corpus <- tm_map(corpus, removeWords, stopwords("es"))
17
18 dtm <- DocumentTermMatrix(corpus)
```

Entrenamiento de modelo LDA

```
1 lda_model <- LDA(dtm, k = 2, control = list(seed = 1234))  
2 terms(lda_model, 5)
```

Salida:

	Topic 1	Topic 2
[1,]	"elecciones"	"gobierno"
[2,]	"país"	"ley"
[3,]	"ciudadanos"	"senado"
[4,]	"votan"	"anuncia"
[5,]	"nuevas"	"aprobada"

Visualización con LDAvis

```
1 library(LDAvis)
2 vis_data <- prepare.LDAvis(lda_model, dtm)
3 ser_vis <- saveLDAvis(vis_data, outfile = "lda.html")
```

Este código genera un archivo HTML interactivo que puedes abrir en tu navegador para explorar visualmente los temas.

Cálculo del Coherence Score $C_v(\text{manual})$

```
1 coherence_cv <- function(topic_words, dtm) {  
2   library(Matrix)  
3   N <- length(topic_words)  
4   score <- 0  
5   count <- 0  
6   for (i in 1:(N-1)) {  
7     for (j in (i+1):N) {  
8       w1 <- topic_words[i]  
9       w2 <- topic_words[j]  
10      df_w1 <- sum(colSums(dtm[, w1]) > 0)  
11      df_w2 <- sum(colSums(dtm[, w2]) > 0)  
12      df_both <- sum(rowSums(dtm[, c(w1, w2)]) == 2)  
13      D <- nrow(dtm)  
14      if (df_w1 > 0 && df_w2 > 0) {  
15        num <- log((df_both + 1e-12) / df_w1)  
16        den <- -log(df_w2 / D)  
17        score <- score + num / den  
18        count <- count + 1  
19      }  
20    }  
21  }  
22  return(score / count)  
23 }
```

¿Qué es la Perplejidad?

- Métrica estadística que mide cómo de bien un modelo predice datos nuevos.
- Cuanto menor sea su valor, mejor será el modelo.
- No siempre refleja la coherencia semántica de los temas.

Fórmula Matemática

Para un conjunto de documentos de prueba D_{test} , la perplejidad se define como:

$$\text{Perplexity}(D_{test}) = \exp \left(- \frac{\sum_{d=1}^M \log p(w_d)}{\sum_{d=1}^M N_d} \right)$$

Donde:

- $\log p(w_d)$: log-verosimilitud del documento d
- N_d : número de palabras en el documento d

Ejemplo Numérico

Documentos de prueba:

- Doc1: ["gobierno", "ley"] $\rightarrow \log p(w_d) = -3,0$
- Doc2: ["país", ".elecciones"] $\rightarrow \log p(w_d) = -4,0$

Total de palabras: $N = 4$

$$\text{Perplexity} = \exp\left(-\frac{-3,0 - 4,0}{4}\right) = \exp\left(\frac{7,0}{4}\right) = \exp(1,75) \approx 5,75$$

Cálculo de Perplejidad en R

```
1 library(topicmodels)
2
3 # Entrenamiento del modelo
4 lda_model <- LDA(dtm_train, k = 2, control = list(seed =
    1234))
5
6 # Cálculo de perplejidad en datos de prueba
7 log_likelihood <- mean(sapply(seq_len(nrow(dtm_test)),
    function(i) {
8     logLikelihood(lda_model, dtm_test[i, ]) # Puede requerir
        funci n auxiliar
9     })))
10
11 num_words <- sum(colSums(dtm_test))
12 perplexity <- exp(-log_likelihood / num_words)
13
14 cat("Perplexity:", perplexity, "\n")
```


Interpretación de los Valores

Valor	Interpretación
< 100	Modelo muy ajustado
$100 - 500$	Modelo razonable
> 500	Modelo poco ajustado

Nota: ¡No garantiza mejores temas interpretativos!

Gráfico Comparativo

coherence_perplexity_plot.png

Función R para Evaluación Automática

```
1 evaluate_lda_models <- function(dtm, k_values = 2:10) {  
2   results <- tibble::tibble(K = integer(), Coherence =  
3     numeric(), Perplexity = numeric())  
4   for (k in k_values) {  
5     lda_model <- LDA(dtm, k = k)  
6     topic_terms <- purrr::map(1:k, ~ terms(lda_model, 10)[,  
7       .x])  
8     coherence_scores <- sapply(topic_terms, coherence_cv,  
9       dtm = dtm)  
10    perplexity <- calcular_perplejidad(...)  
11    results <- bind_rows(results, tibble(K = k, Coherence =  
12      mean(coherence_scores), Perplexity = perplexity))  
13  }  
14  return(results)  
15 }
```

Coherence Score vs Perplexity v2

Ambas métricas ayudan a elegir el número óptimo de temas:

- **Coherence Score**: prioriza temas interpretables.
- **Perplexity**: prioriza ajuste estadístico.

Recomendación: - Usa Coherence Score si buscas temas humanamente comprensibles. - Usa Perplexity si priorizas capacidad predictiva. - Combínalas para equilibrio entre ambos objetivos.

Gráfico Comparativo

coherence_perplexity_plot.png

Interpretación del Score

Rango	Interpretación
0.2 – 0.4	Temas aceptables
0.4 – 0.6	Temas buenos
> 0.6	Temas muy claros y coherentes

Ventajas del Coherence Score C_v

- Combina múltiples enfoques estadísticos.
- Correlaciona bien con evaluación humana.
- Fácil de interpretar e implementar.

Limitaciones

- No garantiza perfectamente la relevancia semántica.
- Puede verse afectado por ruido en el texto.
- Es sensible al preprocesamiento.

Conclusión

- El Coherence Score
- C_v es una herramienta clave para evaluar modelos de topic modeling.
- En R, se puede usar 'topicmodels' y funciones personalizadas para calcularlo.
- La Perplejidad complementa esta evaluación desde una perspectiva estadística.
- Ambas métricas ayudan a elegir el número óptimo de temas.

Referencias



M. Röder, A. Both, A. Hinze. *Exploring the Space of Topic Coherence Measures*. In Proceedings of WSDM, 2015.



B. Grün and K. Hornik (2011). *topicmodels: An R Package for Fitting Topic Models*. Journal of Statistical Software, 40(13), 1–30.



Chase, D. M. (2015). LDAvis: A Method for Visualizing and Interpreting Topics.