

EST-297

Modelos de Clustering para Texto

Juan Zamora O.

Ciencia de Datos



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

Estructura de la Presentación


- 1 Aproximaciones Low-Rank para Clustering
- 2 (NMF) Factorización de matrices no-negativas
- 3 NMF
- 4 Aplicación de NMF para extracción de tópicos en texto

Aproximaciones Low-Rank para Clustering

Una matriz X de rango r admite una factorización de la forma

$$X = BC^T, \quad B \in \mathbf{R}^{m \times r}, \quad C \in \mathbf{R}^{n \times r}$$

X es aproximada con bajo rango (low-rank) cuando $\text{rango}(X) \ll \min(m, n)$



(NMF) Factorización de matrices no-negativas

- Grupo de algoritmos de análisis multivariado y álgebra lineal donde una matriz X es factorizada en dos matrices W y H
- Cada columna de X es aproximada por una combinación lineal no-negativa de las columnas de W , donde los coeficientes de mezcla corresponden a las columnas de H
- Las tres matrices tienen elementos no-negativos
- Usado en sistemas recomendadores, procesamiento de audio, agrupamiento de texto.

NMF

- Dada una matriz no-negativa $X \in \mathbf{R}^{m \times n}$ y un $k \in \mathbf{Z} \ll \min(m, n)$
- Encuentra matrices no-negativas $W \in \mathbf{R}^{m \times k}$ y $H \in \mathbf{R}^{k \times n}$ tales que minimizan

$$\|X - WH\|_F^2 = \sum_i \sum_j (X_{ij} - [WH]_{ij})^2$$

- W : base para un espacio k -dimensional, la i -ésima columna de H : corresponde a representación k -dim de i -ésima columna de X

Método de Lee y Seung (2001)

Lee y Seung propusieron reglas de actualización multiplicativas para minimizar:

$$\min_{W, H \geq 0} \|V - WH\|_F^2$$

Las reglas de actualización son:

$$H \leftarrow H \circ \frac{W^\top V}{W^\top W H}$$
$$W \leftarrow W \circ \frac{V H^\top}{W H H^\top}$$

donde $\circ$ denota el producto elemento a elemento (Hadamard).

Ejemplo numérico: datos iniciales

Matriz original y objetivo

Matriz original V :

$$V = \begin{bmatrix} 5 & 3 \\ 3 & 2 \\ 4 & 1 \end{bmatrix}$$

Factorizar $V \approx WH$, con $W \in \mathbb{R}_{\geq 0}^{3 \times 2}$, $H \in \mathbb{R}_{\geq 0}^{2 \times 2}$.

Inicialización

Matrices iniciales:

$$W^{(0)} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \\ 1 & 1 \end{bmatrix}, \quad H^{(0)} = \begin{bmatrix} 1 & 2 \\ 1 & 1 \end{bmatrix}$$

Iteración 1: Actualización de H

$$H_{ij} \leftarrow H_{ij} \times \frac{(W^T V)_{ij}}{(W^T W H)_{ij}}$$

$$W^T V = \begin{bmatrix} 9.5 & 4.0 \\ 9.5 & 4.5 \end{bmatrix}, \quad W^T W H^{(0)} = \begin{bmatrix} 4.25 & 6.5 \\ 4.25 & 6.25 \end{bmatrix}$$

$$H^{(1)} = \begin{bmatrix} 2.235 & 1.231 \\ 2.235 & 0.72 \end{bmatrix}$$

Iteración 1: Actualización de W

$$W_{ij} \leftarrow W_{ij} \times \frac{(VH^T)_{ij}}{(WHH^T)_{ij}}$$

$$VH^{(1)T} = \begin{bmatrix} 14.88 & 13.365 \\ 9.21 & 8.085 \\ 10.171 & 9.16 \end{bmatrix}, \quad W^{(0)}H^{(1)}H^{(1)T} = \begin{bmatrix} 9.54 & 8.49 \\ 8.06 & 8.4 \\ 12.6 & 11.26 \end{bmatrix}$$

$$W^{(1)} = \begin{bmatrix} 1.56 & 0.79 \\ 0.57 & 0.96 \\ 0.81 & 0.81 \end{bmatrix}$$

Iteración 2: Actualización de H

$$W^{(1)T}V = \begin{bmatrix} 13.89 & 6.75 \\ 11.37 & 5.04 \end{bmatrix}, \quad W^{(1)T}W^{(1)}H^{(1)} = \begin{bmatrix} 12.98 & 5.76 \\ 9.94 & 4.21 \end{bmatrix}$$

$$H^{(2)} = \begin{bmatrix} 2.39 & 1.44 \\ 2.56 & 0.86 \end{bmatrix}$$

Iteración 2: Actualización de W

$$VH^{(2)T} = \begin{bmatrix} 20.35 & 17.45 \\ 12.87 & 11.12 \\ 11.98 & 10.17 \end{bmatrix}, \quad W^{(1)}H^{(2)}H^{(2)T} = \begin{bmatrix} 18.1 & 15.7 \\ 14.9 & 13.2 \\ 15.9 & 14.2 \end{bmatrix}$$

$$W^{(2)} = \begin{bmatrix} 1.75 & 0.88 \\ 0.49 & 0.81 \\ 0.61 & 0.58 \end{bmatrix}$$

Iteración 3: Actualización de H

$$W^{(2)T}V = \begin{bmatrix} 14.6 & 7.1 \\ 11.4 & 5.2 \end{bmatrix}, \quad W^{(2)T}W^{(2)}H^{(2)} = \begin{bmatrix} 13.9 & 6.1 \\ 10.7 & 4.7 \end{bmatrix}$$

$$H^{(3)} = \begin{bmatrix} 2.51 & 1.68 \\ 2.73 & 0.95 \end{bmatrix}$$

Iteración 3: Actualización de W

$$VH^{(3)T} = \begin{bmatrix} 21.2 & 18.1 \\ 13.2 & 11.5 \\ 12.1 & 10.5 \end{bmatrix}, \quad W^{(2)}H^{(3)}H^{(3)T} = \begin{bmatrix} 19.3 & 16.8 \\ 15.8 & 14.0 \\ 16.8 & 15.0 \end{bmatrix}$$

$$W^{(3)} = \begin{bmatrix} 1.92 & 0.95 \\ 0.41 & 0.67 \\ 0.44 & 0.41 \end{bmatrix}$$

Iteración 4: Actualización de H y resultado final

$$W^{(3)T}V = \begin{bmatrix} 15.1 & 7.3 \\ 11.2 & 5.0 \end{bmatrix}, \quad W^{(3)T}W^{(3)}H^{(3)} = \begin{bmatrix} 14.6 & 6.4 \\ 10.9 & 4.7 \end{bmatrix}$$

$$H^{(4)} = \begin{bmatrix} 2.60 & 1.92 \\ 2.80 & 1.01 \end{bmatrix}$$

Resultado final aproximado:

$$W^{(4)} \approx \begin{bmatrix} 1.92 & 0.95 \\ 0.41 & 0.67 \\ 0.44 & 0.41 \end{bmatrix}, \quad H^{(4)} \approx \begin{bmatrix} 2.60 & 1.92 \\ 2.80 & 1.01 \end{bmatrix}$$


y

$$W^{(4)}H^{(4)} \approx V$$


Aplicación de NMF para extracción de tópicos en texto

- Se construye matriz de terminos vs documentos
- Se aplica NMF para obtener W y H

Basis vectors W : topics (clusters)



Coefficients H : memberships for documents



Clustering y Modelos estadísticos de Texto

- Abundante en diversos dominios (redes sociales, medios digitales, registros en salud ...)
- Resulta útil poder explorar estas colecciones de alguna manera asistida
- Clustering permite caracterizar de manera **automática** una colección de documentos
- A finales de los 90, aparecieron varios modelos estadístico de texto usando un modelo de mezcla sobre variables aleatorias multinomiales
 - LSI
 - pLSI

¿Qué es LDA?

- LDA aparece a principio del 2000
- Incluye un modelo generativo para los documentos, además de los tópicos
- Cada documento es una mezcla de temas
- Cada tema es una distribución de palabras
- Distribución apriori de tópicos es una Dirichlet

Referencias: [Blei et al. 2003](#)

Distribuciones de probabilidad en LDA

- $\theta_d \sim \text{Dirichlet}(\alpha)$: distribución de temas en un documento.
- $\phi_k \sim \text{Dirichlet}(\beta)$: distribución de palabras en un tema.
- $z_{d,n} \sim \text{Multinomial}(\theta_d)$: elección de tema para palabra n en documento d .
- $w_{d,n} \sim \text{Multinomial}(\phi_{z_{d,n}})$: elección de palabra según el tema.

Estimación de parámetros

- El modelo observa solo las palabras. Los temas son variables latentes.
- Se busca inferir:
 - θ_d : proporción de temas en cada documento.
 - ϕ_k : distribución de palabras por tema.
 - $z_{d,n}$: asignación de temas a palabras.
- Métodos comunes:
 - Muestreo de Gibbs (Gibbs Sampling)
 - Inferencia variacional (Variational Bayes)



¿Qué es Gibbs Sampling?

- Método de Monte Carlo para estimar distribuciones condicionales.
- En LDA:
 - Se fija el tema de todas las palabras excepto una.
 - Se estima la probabilidad condicional de cada posible tema para esa palabra.
 - Se repite este proceso para todas las palabras, muchas veces.
- El resultado converge a una estimación de la distribución posterior conjunta.

Ejemplo de las palabras más representativas en 11 tópicos

Topic 1 <chr>	Topic 2 <chr>	Topic 3 <chr>	Topic 4 <chr>	Topic 5 <chr>	Topic 6 <chr>	Topic 7 <chr>	Topic 8 <chr>	Topic 9 <chr>	Topic 10 <chr>	Topic 11 <chr>
internacionalización	región	desarrollo	importante	prestigio	problemas	mejoras	tiempo	inclusiva	formación	académicos
nacional	valparaíso	medio	áreas	futuro	sociales	universidades	profesores	innovadora	profesional	comunidad
investigación	institución	vinculación	vanguardia	educación	desarrollo	aporte	profesional	estudiantes	calidad	estudiantes
región	comunidad	investigación	personas	estudiantes	temas	país	cambio	aprendizaje	nuevas_tecnologías	personas
liderazgo	entorno	estudiantes	estudios	programas	excelente	calidad	mejoras	abierta	procesos	funcionarios
reconocida	compromiso	sostenible	compleja	calidad	institución	desarrollo	mundo	personas	valores	conocimientos
referente	local	innovadora	espacios	carreras	resolver	conocimientos	tiempos	desarrollar	continua	oportunidad
proyectos	tradición	ambiente	nuevas_tecnologías	chile	público	infraestructura	puedan	investigación	institución	preocupada
áreas	ciudad	permitan	carreras	mejoras	país	enseñanza	gestión	más_inclusiva	trabajo	espacios
manteniendo	nacional	institución	territorio	mundo	comprometida	tres	investigación	calidad	estudiantes	servicio

Asociación texto y tópico



¿De qué sirve esta perspectiva generadora de documentos?

- Existen técnicas estadísticas y computacionales para invertir este procedimiento a partir de documentos existentes (...nuestros documentos), pudiendo así inferir la composición **más probable** de los tópicos que permitieron generar esta colección de documentos.
- Los tópicos estimados tienen un significado identificado por el/la analista

Evaluación de modelos LDA

- Evaluar la calidad de los tópicos descubiertos no es trivial
 - **No existe** una “respuesta correcta” contra la cual comparar.

Existen dos enfoques complementarios:

- **Perplexity:** métrica estadística que mide qué tan bien el modelo predice datos no vistos (ajuste probabilístico).
 - Blei, Ng & Jordan (2003)
- **Coherence:** métrica semántica que mide si las palabras de un tópico tienen sentido conjunto para un humano.
 - Newman et al. (2010) y Röder et al. (2015) posteriormente mostraron que perplexity no siempre se correlaciona con interpretabilidad humana.

Perplexity

Mide la capacidad del modelo de predecir un conjunto de documentos no usados en el entrenamiento (**held-out**). Se basa en la **log-verosimilitud** del modelo.

(Blei, Ng & Jordan, 2003):

$$\text{Perplexity}(D_{test}) = \exp \left(-\frac{\sum_{d=1}^M \log p(w_d)}{\sum_{d=1}^M N_d} \right)$$

donde:

- D_{test} = conjunto de documentos de prueba (**held-out**), de tamaño M
- M = número total de documentos en D_{test}
- w_d = vector de palabras (todos los tokens) del documento d
- N_d = número de palabras (tokens) en el documento d
- $p(w_d)$ = probabilidad del documento d , marginalizando sobre tópicos:

$$p(w_d) = \prod_{i=1}^{N_d} \sum_{k=1}^K p(w_{d,i} | z_{d,i} = k) p(z_{d,i} = k | d)$$

Acerca de la notación: M aparece en ambas sumatorias (numerador y denominador)

— El numerador es la log-verosimilitud total del corpus de prueba; el denominador es el número total de tokens en ese mismo corpus.

Interpretación:

- Rango: $(0, \infty)$
- **Menor perplexity = mejor modelo** (el modelo está menos “sorprendido” por datos nuevos)
- Perplexity decreciente indica mejor ajuste estadístico del modelo a los datos
 - No garantiza tópicos interpretables

Coherence

Mide si las palabras top de un tópico co-ocurren de manera consistente en los documentos, capturando la interpretabilidad semántica.

UMass Coherence, Mimno et al. 2011:

$$C_{UMass}(t) = \sum_{i=2}^N \sum_{j=1}^{i-1} \log \frac{D(w_i, w_j) + 1}{D(w_j)}$$

donde:

- $w_1, \dots, w_N$ = las N palabras más probables del tópico t (ordenadas por relevancia)
- $D(w_j)$ = número de documentos donde aparece la palabra w_j
- $D(w_i, w_j)$ = número de documentos donde co-ocurren w_i y w_j
- El $+1$ es un suavizado (Laplace) para evitar $\log(0)$

Variante más usada en la práctica — Coherence C_v (Röder et al., 2015):

- Combina similitud coseno de vectores ***Normalized Pointwise Mutual Information*** con una ventana deslizante de co-ocurrencia
- Muestra mejor correlación con juicio humano que UMass.

Interpretación:

- **Mayor coherence = tópicos más interpretables** (palabras que tienden a aparecer juntas)
- Valores de C_v suelen ubicarse entre 0.3 y 0.7 en corpus reales
- Valores >0.5 son considerados aceptables

Los rangos varían según la métrica:

Métrica	Rango	Interpretación
C_v (histórica)	$[0, 1]$	Mayor = mejor; típicamente 0.4–0.7; NO recomendada
C_{UMass}	$(-\infty, 0]$	Mayor (menos negativo) = mejor; -2 a -10 típico
C_{UCI} (PMI)	$(-\infty, +\infty)$	Mayor = mejor; típicamente -1 a $+2$
C_{NPMI} (normalizado)	$[-1, +1]$	Mayor = mejor; 0.0 a 0.2 común en LDA

Validación y selección de modelos

Flujo de trabajo recomendado:

- 1 **Entrenar múltiples modelos LDA** variando el número de tópicos k
- 2 **Calcular perplexity** sobre un conjunto **held-out** para cada k , se grafica curva y busca el “codo” donde deja de mejorar sustancialmente
- 3 **Calcular coherence** (C_v o UMass) para cada k , buscar el máximo o un punto estable alto
- 4 **Triangular ambas métricas:** rara vez coinciden exactamente en el mismo k , prioriza **coherence** para interpretabilidad
- 5 **Validación humana final:** inspeccionar manualmente las top-X palabras de los tópicos del modelo candidato antes de decidir

Advertencia respecto a la cantidad de tópicos

- Más tópicos = mejor ajuste estadístico **pero** tópicos redundantes o fragmentados
- **Chang et al. (2009)** demostraron que perplexity puede mejorar mientras la interpretabilidad humana empeora
 - Coherence se considera el estándar en la práctica

Ejemplo en R (paquete topicmodels + ldatuning):

```
library(ldatuning)
```

```
# CaoJuan2009 y Griffiths2004 son métricas similares a Coherence
```

```
resultado <- FindTopicsNumber(  
  dtm,  
  topics = seq(2, 15, by = 1),  
  metrics = c("Griffiths2004", "CaoJuan2009", "Deveaud2014"),  
  method = "Gibbs",  
  control = list(seed = 42, iter = 500),  
  mc.cores = 2L  
)
```

```
FindTopicsNumber_plot(resultado)
```

Referencias

- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). "Latent Dirichlet Allocation." *Journal of Machine Learning Research*, 3, 993–1022.
- Chang, J., Gerrish, S., Wang, C., Boyd-Graber, J., & Blei, D. (2009). "Reading tea leaves: How humans interpret topic models." *Advances in Neural Information Processing Systems*, 22.
- Mimno, D., Wallach, H., Talley, E., Leenders, M., & McCallum, A. (2011). "Optimizing semantic coherence in topic models." *Proceedings of EMNLP*, 262–272.
- Röder, M., Both, A., & Hinneburg, A. (2015). "Exploring the space of topic coherence measures." *Proceedings of WSDM*, 399–408.
- Newman, D., Lau, J. H., Grieser, K., & Baldwin, T. (2010). "Automatic evaluation of topic coherence." *Proceedings of NAACL*, 100–108.