

Análisis de Datos

Estadística Computacional

Juan Zamora Osorio
juan.zamora@pucv.cl

Instituto de Estadística
Pontificia Universidad Católica de Valparaíso



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

Terminología

Dato

- ▶ Del latín *datum*, es una representación simbólica, un atributo o una característica de una entidad o cosa.
- ▶ *Observación* de un fenómeno con una escala de medida.

Población objetivo (universo de estudio) (Ω)

- ▶ Colección de todas las unidades posibles consideradas.

Muestra

- ▶ Lo que conocemos de una población.
- ▶ Es una imagen (sinopsis) del todo.
- ▶ $M = \{\omega_1, \omega_2, \dots, \omega_n\} \subseteq \Omega$ muestra de n datos.

Terminología

Dato

- ▶ Del latín *datum*, es una representación simbólica, un atributo o una característica de una entidad o cosa.
- ▶ *Observación* de un fenómeno con una escala de medida.

Cuidado

- ▶ Recordar que el dato no corresponde a la realidad misma, sino a su representación

Datos categóricos / discretos / nominales / cualitativos

Ejemplos

- ▶ Género: masculino, femenino, no binari@.
- ▶ Nacionalidad: Chile, Argentina, Perú, etc.
- ▶ Color de ojos.
- ▶ Ha salido fuera del país: sí, no.



Datos ordinales

Ejemplos

- ▶ Edad: 0, 1 año, 2 años, etc.
- ▶ Cantidad de hijo/as: 0, 1, 2, 3, etc.
- ▶ Talla de zapatos.
- ▶ Niveles de educación (?).



Datos continuos

Ejemplos

- ▶ Tiempo que demora en caer un objeto.
- ▶ Distancia al lanzar una piedra.
- ▶ Precio de una acción en la bolsa.
- ▶ Temperatura.
- ▶ Ángulo que apunta una ruleta.
- ▶ Segundos desde 1970 (?).



Escalas de medida

Escala	Operaciones empíricas básicas	Estructura matemática de grupo	Estadísticos invariantes
Nominal	Igualdad	Grupo de permutaciones $x' = f(x)$, con $f(x)$ cualquier sustitución uno a uno	Número de casos, moda, correlación de contingencia
Ordinal	Mayor o menor	Grupo isotónico $x' = f(x)$, con $f(x)$ cualquier función monótona	Mediana, percentiles (cuantiles)
Intervalar	Igualdad de intervalos o diferencias	Grupo lineal general $x' = ax + b$	Media, desviación estándar, correlaciones
De razón	Igualdad de razones	Grupo de similaridad $x' = ax'$	Coefficiente de variación

Terminología – Tipos de datos

Según cantidad de variables

- ▶ Univariados.
- ▶ Bivariados.
- ▶ Multivariados.

Cuidado

Muchos fenómenos se representan por medio de datos mezclados (estructurados o no estructurados).

Conjunto de datos

Qué es

- ▶ Recordar: una representación de la cosa.
- ▶ Descripciones de distintas instancias de un mismo fenómeno.
- ▶ Similar a una “muestra”.
- ▶ Representados como tuplas, matrices, tensores, grafos, imágenes, etc.

Dato	Atributo 1	Atributo 2	...	Atributo p
1	$x_{1,1}$	$x_{1,2}$	...	$x_{1,p}$
2	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
n	$x_{n,1}$	$x_{n,2}$	...	$x_{n,p}$

$$\left(\begin{array}{ccccc} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ 2 & x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ n & x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{array} \right)$$

$n \times p$

Conjunto de datos como matriz

Ejemplo: despachos de una cadena de pizzerías

Entrega	Tiempo entrega	Temperatura	...	Sucursal
1	35,1	68,3	...	Este (1)
2	25,2	71,0	...	Este (1)
⋮	⋮	⋮	⋮	⋮
1266	35,7	60,8	...	Oeste (2)

Decisiones / transformaciones

- ▶ ¿Unidades?
- ▶ ¿Cómo representar datos categóricos?
- ▶ 1, 2, 3, 4.
- ▶ 0001, 0010, 0100, 1000.

Frecuencias

Ejemplo: alumnos presentes

► S, N, S, N, S, S, S, N, S, S.

Frecuencias

► Absoluta:

► $n_S = 7.$

► $n_N = 3.$

► Relativa:

► $f_S = \frac{n_S}{n} = \frac{7}{10} = 0,7.$

► $f_N = \frac{n_N}{n} = \frac{3}{10} = 0,3.$

¿Y los datos continuos?

Agrupando


- Podemos agrupar por intervalos.

Ejemplo: notas de control



- 28, 35, 42, 90, 70, 56, 75, 66, 30, 89, 75, 64, 81, 69, 55, 83, 72, 68, 73, 16.

0 – 20	21 – 40	41 – 60	61 – 80	81 – 100
$n_1 = 1$	$n_2 = 3$	$n_3 = 3$	$n_4 = 9$	$n_5 = 4$
$f_1 = \frac{1}{20}$	$f_2 = \frac{3}{20}$	$f_3 = \frac{3}{20}$	$f_4 = \frac{9}{20}$	$f_5 = \frac{4}{20}$

Visualización: gráfico de torta





Visualización: gráfico de torta



Visualización: gráfico de barras

Ejemplo: alumnos presentes



► S, N, S, N, S, S, S, N, S, S.



Visualización: gráfico de barras apilado

Frecuencia absoluta versus relativa

- ¿Cuál es la diferencia entre utilizar la frecuencia absoluta y la relativa?



Visualización: gráfico de barras



Visualización: gráfico de barras

Porcentaje que se paga de impuestos:




Gráfico de tallo-hojas

Notas de control

- ▶ 28, 35, 42, 90, 70, 56, 75, 66, 30, 89, 75, 64, 81, 69, 55, 83, 72, 68, 73, 16.

0	
1	6
2	8
3	05
4	2
5	56
6	4689
7	02355
8	139
9	0

Gráfico de tallo-hojas

Notas de control

- ▶ 28, 35, 42, 90, 70, 56, 75, 66, 30, 89, 75, 64, 81, 69, 55, 83, 72, 68, 73, 16.





Gráfico de tallo-hojas

Notas de control

- 28, 35, 42, 90, 70, 56, 75, 66, 30, 89, 75, 64, 81, 69, 55, 83, 72, 68, 73, 16.





Heurística: ley de Benford

Dependiendo del dominio, tienden a agruparse en los números más pequeños, especialmente dominios abiertos de razón.



Histograma

Notas de control

- ▶ 28, 35, 42, 90, 70, 56, 75, 66, 30, 89, 75, 64, 81, 69, 55, 83, 72, 68, 73, 16.




Histograma – continuo




Histograma – ejemplos demanda eléctrica


Pan de Azúcar



Quillota




San Joaquín




Histograma – ejemplo demanda eléctrica


Datos originales





Aplicando logaritmo







Histograma – polígono de frecuencias



Histograma – frecuencia acumulada





Histograma – ¿cuántos intervalos?



Heurística: regla de Sturges

- ▶ Se puede elegir cantidad $k = 1 + \log_2 n$, donde k es la cantidad de clases (intervalos) y n la cantidad de datos.
- ▶ Alternativamente, puede usarse $k = 1 + 3,322 \times \log_{10} n$.


Nota al margen – Kernel Density Plot



Otros asuntos

- ▶ Mezcla de gaussianas (normales).
- ▶ Ventanas de Parzen.


Un ejemplo: palabras en libros en inglés



Preguntas


Largo de palabras en castellano

¿Con qué tipo de dato se está trabajando? ¿Qué significa que la frecuencia relativa de las palabras de largo 15 o más sea 0,004?



Horas de juego de juegos video

¿Qué histograma considera más apropiado para explorar las propiedades de la cantidad de horas?



Medidas de localización

Media muestral (media aritmética)

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{\sum_{i=1}^n x_i}{n}.$$

- Busca estimar la *media* de la población, denotada como μ .

Ejemplo: temperaturas máximas durante enero

- 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.
- $\bar{x} = \frac{22+24+21+\cdots+28+29}{31} = 26,48 \text{ }^{\circ}\text{C}.$

Media muestral – promedio

Ejemplo: temperaturas máximas durante enero

- 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

< 20	$(20, 25]$	$(25, 30]$	$(30, 35]$	> 35
$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$f_1 = 0$	$f_2 = \frac{12}{31}$	$f_3 = \frac{18}{31}$	$f_4 = \frac{1}{31}$	$f_5 = 0$

Datos agrupados

- Se debe elegir **marca de clase** (representante de la clase).
- Ejemplo: valor medio de cada intervalo: $m_j = \frac{e_{j-1} + e_j}{2}$.
- Media aritmética con pesos $\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j m_j = \sum_{j=1}^k f_j m_j$.
- Ejemplo: $\bar{x} = 0 + \frac{12}{31}22,5 + \frac{18}{31}27,5 + \frac{1}{31}32,5 + 0 \approx 25,7 \text{ } ^\circ\text{C}$.

Media muestral – promedio

Ejemplo: temperaturas máximas durante enero

- 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

< 20	$(20, 25]$	$(25, 30]$	$(30, 35]$	> 35
$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$f_1 = 0$	$f_2 = \frac{12}{31}$	$f_3 = \frac{18}{31}$	$f_4 = \frac{1}{31}$	$f_5 = 0$

Datos agrupados

- Para evitar el problema: media de medias.

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j \bar{x}_j = \sum_{j=1}^k f_j \bar{x}_j.$$

- Ejemplo: $\bar{x} = 0 + \frac{12}{31}23,83 + \frac{18}{31}28 + \frac{1}{31}31 + 0 = 26,48 \text{ }^{\circ}\text{C}.$

Medidas de localización

Mediana muestral

$$\tilde{x}_{0,5} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar,} \\ \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right) & \text{si } n \text{ es par.} \end{cases}$$

- ▶ x_i observación i -ésima.
- ▶ $x_{(i)}$ estadística de orden i -ésima.
- ▶ $x_{(1)} = \min\{x_i\}_{i=1}^n$ y $x_{(n)} = \max\{x_i\}_{i=1}^n$.

Ejemplo: temperaturas máximas durante enero

21	22	22	23	24	24	25	25	25	25	25	25	26	26	26	26
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
27	27	27	28	28	28	29	29	29	29	29	30	30	30	31	
17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	

- ▶ $\tilde{x}_{0,5} = 26^{\circ}\text{C}$.

Mediana muestral – datos agrupados

Ejemplo: temperaturas máximas durante enero

- 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.


< 20	$(20, 25]$	$(25, 30]$	$(30, 35]$	> 35
$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$f_1 = 0$	$f_2 = \frac{12}{31}$	$f_3 = \frac{18}{31}$	$f_4 = \frac{1}{31}$	$f_5 = 0$

Datos agrupados


- Clase m es la clase que cumple que $\sum_{j=1}^{m-1} f_j < 0,5$ y $\sum_{j=1}^m f_j \geq 0,5$.
- Mediana interpolada $\tilde{x}_{0,5} = e_{m-1} + \frac{0,5 - \sum_{j=1}^{m-1} f_j}{f_m} (e_m - e_{m-1})$.
- Ejemplo: $\tilde{x}_{0,5} = 25 + \frac{0,5 - \frac{12}{31}}{\frac{18}{31}} 5 \approx 25,97$ °C.

Media vs mediana


Simétricos




Asimétricos



Bimodales



Valores atípicos / extremos



Generalización de la mediana

Cuantiles

$$\tilde{x}_\alpha = \begin{cases} x_{(\lceil n\alpha \rceil)} & \text{si } n\alpha \text{ no es entero,} \\ \frac{1}{2}(x_{(n\alpha)} + x_{(n\alpha+1)}) & \text{si } n\alpha \text{ es entero.} \end{cases}$$


- ¿Es la única manera de interpolar?

Ejemplo: temperaturas máximas durante enero

21	22	22	23	24	24	25	25	25	25	25	25	26	26	26	26
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
27	27	27	28	28	28	29	29	29	29	29	30	30	30	31	
17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	

- $\tilde{x}_{0,25} = x_{(\lceil 7\frac{3}{4} \rceil)} = x_{(8)} = 25^\circ\text{C}.$
- $\tilde{x}_{0,5} = x_{(\lceil 15\frac{1}{2} \rceil)} = x_{(16)} = 26^\circ\text{C}.$
- $\tilde{x}_{0,75} = x_{(\lceil 23\frac{1}{4} \rceil)} = x_{(24)} = 29^\circ\text{C}.$

Cuantiles y frecuencia acumulada



- Deciles, quintiles, cuartiles, etc.

Medidas de dispersión / variabilidad

Rango

► $R = x_{(n)} - x_{(1)} = \max\{x_i\}_{i=1}^n - \min\{x_i\}_{i=1}^n.$

Rango intercuantil

► $Q_\alpha = \tilde{x}_{\frac{1+\alpha}{2}} - \tilde{x}_{\frac{1-\alpha}{2}}.$

► Ejemplo: intercuantil $\alpha = 0,5$: $Q_{0,5} = \tilde{x}_{0,75} - \tilde{x}_{0,25}.$


Ejemplo: temperaturas máximas durante enero

21	22	22	23	24	24	25	25	25	25	25	25	26	26	26	26
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
27	27	27	28	28	28	29	29	29	29	29	30	30	30	31	
17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	

► $R = 31 - 21 = 10 \text{ }^{\circ}\text{C}.$

► $Q_{0,5} = 29 - 25 = 4 \text{ }^{\circ}\text{C}.$

Gráfico de caja (*boxplot*)




Valores atípicos / extremos (*outliers*)

- ▶ $Q_{0,5} = \tilde{x}_{0,75} - \tilde{x}_{0,25}$.
- ▶ x_i valor atípico si $x_i - \tilde{x}_{0,75} > 1,5Q_{0,5}$, o si $\tilde{x}_{0,25} - x_i > 1,5Q_{0,5}$.
- ▶ x_i valor extremo si $x_i - \tilde{x}_{0,75} > 3Q_{0,5}$, o si $\tilde{x}_{0,25} - x_i > 3Q_{0,5}$.
- ▶ Estas definiciones varían según libro, biblioteca, etc. Es configurable.

Asimetría (*skewness*)

Coeficiente/índice de Bowley / Yule

$$\frac{(\tilde{x}_{0,75} - \tilde{x}_{0,5}) - (\tilde{x}_{0,5} - \tilde{x}_{0,25})}{\tilde{x}_{0,75} - \tilde{x}_{0,25}} = \frac{\tilde{x}_{0,25} + \tilde{x}_{0,75} - 2\tilde{x}_{0,5}}{\tilde{x}_{0,75} - \tilde{x}_{0,25}}.$$



Medidas de localización

Moda

- ▶ El valor más frecuente.
- ▶ Puede haber más de un valor modal.

Ejemplo: temperaturas máximas durante enero

- ▶ 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

21	22	22	23	24	24	25	25	25	25	25	25	26	26	26	26
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
27	27	27	28	28	28	29	29	29	29	29	30	30	30	31	
17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	

- ▶ Moda = 25 °C.

Moda – datos agrupados

Moda

- ▶ El intervalo / clase más frecuente.
- ▶ ¿Cuál es su representante?

Ejemplo: temperaturas máximas durante enero

- ▶ 22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26, 25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

< 20	$(20, 25]$	$(25, 30]$	$(30, 35]$	> 35
$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$f_1 = 0$	$f_2 = \frac{12}{31}$	$f_3 = \frac{18}{31}$	$f_4 = \frac{1}{31}$	$f_5 = 0$

- ▶ Clase modal es intervalo $(25, 30]$ °C.

Medidas de dispersión / variabilidad / volatilidad

Desviación absoluta

$$D(A) = \frac{1}{n} \sum_{i=1}^n |x_i - A|.$$

Ejemplo: desviación absoluta de la media

$$D(\bar{x}) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|.$$

Mínimo: se obtiene con la mediana $\tilde{x}_{0,5}$

$$D(\tilde{x}_{0,5}) = \frac{1}{n} \sum_{i=1}^n |x_i - \tilde{x}_{0,5}|.$$

Medidas de dispersión / variabilidad / volatilidad

Error cuadrático medio

$$s^2(A) = \frac{1}{n} \sum_{i=1}^n (x_i - A)^2.$$

Mínimo: se obtiene con la media $\bar{x}$, y a su valor se le llama **varianza**

$$s^2(\bar{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i^2 - \bar{x}^2) = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2.$$

Varianza muestral

► $\bar{x}$ es una estimación de μ , la media de la población.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \sum_{i=1}^n x_i^2 - \frac{n}{n-1} \bar{x}^2.$$

Varianza – desviación estándar

Datos agrupados / Datos muestrales

$$s^2 \approx \frac{1}{n-1} \sum_{j=1}^k n_j (m_j - \bar{x})^2 \approx \frac{n}{n-1} \sum_{j=1}^k f_j (m_j - \bar{x})^2.$$

$$s^2 \approx \frac{1}{n-1} \sum_{j=1}^k n_j (\bar{x}_j - \bar{x})^2 \approx \frac{n}{n-1} \sum_{j=1}^k f_j (\bar{x}_j - \bar{x})^2.$$

Ejemplo: temperaturas máximas durante enero

< 20	$(20, 25]$	$(25, 30]$	$(30, 35]$	> 35
$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$f_1 = 0$	$f_2 = \frac{12}{31}$	$f_3 = \frac{18}{31}$	$f_4 = \frac{1}{31}$	$f_5 = 0$

Nota al margen – varianza entre - intra clases

Clase j

- Media $\bar{x}_j = \frac{1}{n_j} \sum_{i \in \text{Clase } j} x_i$, varianza

$$s_j^2 = \frac{1}{n} \sum_{i \in \text{Clase } j} (x_i - \bar{x}_j)^2.$$

Intervalo	< 20	(20, 25]	(25, 30]	(30, 35]	> 35
n_j	$n_1 = 0$	$n_2 = 12$	$n_3 = 18$	$n_4 = 1$	$n_5 = 0$
$\bar{x}_j$	–	23,83	28	31	–
s_j^2	–	1,972	2	0	–

Varianza entre clases e intra clases


$$s^2 = \left[\frac{1}{n} \sum_{j=1}^k n_j (\bar{x}_j - \bar{x})^2 \right] + \left[\frac{1}{n} \sum_{j=1}^k n_j s_j^2 \right].$$

- $\frac{1}{31} \left(12[23,83 - 26,48]^2 + 18[28 - 26,48]^2 + 1[31 - 26,48]^2 \right) + \frac{1}{31} (12 \cdot 1,972 + 18 \cdot 2 + 1 \cdot 0) \approx 4,71 + 1,925 .$

Nota al margen – varianza entre - intra clases

Varianza entre clases e intra clases

$$s^2 = \left[\frac{1}{n} \sum_{j=1}^k n_j (\bar{x}_j - \bar{x})^2 \right] + \left[\frac{1}{n} \sum_{j=1}^k n_j s_j^2 \right].$$



Algunas propiedades

Transformaciones lineales $y_i = a + bx_i$

- ▶ $\bar{y} = a + b\bar{x}$.
- ▶ $s_y^2 = b^2 s_x^2$.
- ▶ $s_y = |b|s_x$.

Ejemplo: estandarización

$$y_i = \frac{x_i - \bar{x}}{s_x}.$$

- ▶ $\bar{y} = 0, s_y = 1$.

Otras transformaciones



- ▶ $y_i = ax_i^2, y_i = a\sqrt{x_i}$.
- ▶ $y_i = \ln x_i$.

Medidas de dispersión / variabilidad

Coeficiente de variación

$$v = \frac{s}{\bar{x}}$$

- ▶ Solo para valores positivos de razón.
- ▶ Permite comparar poblaciones con unidades diferentes, ya que si $y_i = bx_i$, se cumple que $v_y = \frac{s_y}{\bar{y}} = \frac{bs_x}{b\bar{x}} = \frac{s_x}{\bar{x}} = v_x$.
- ▶ A $\frac{\bar{x}}{s}$ se le llama *razón señal ruido*.




Otras medidas: momentos

No centrados

$$m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

Centrados


$$\bar{m}_k = \frac{1}{n} \sum_{i=1}^n (x_i - m_1)^k$$




Tercer momento: asimetría (*skewness*)

Coeficiente de Fisher


$$\frac{\bar{m}_3}{s^3}.$$



Negativa



Simétrica



Positiva

Recordar


- Coeficiente de variación (inversa de razón señal ruido):

$$\frac{s}{\bar{x}} = \sqrt{\frac{\bar{m}_2}{\bar{x}^2}}.$$

Cuarto momento: curtosis / apuntamiento (*kurtosis*)

Coeficiente

$$\frac{\bar{m}_4}{s^4} - 3.$$





► ¿3?

Medidas de concentración

Curva de Lorenz

$$u_i = \frac{i}{n},$$

$$v_i = \frac{\sum_{p=1}^i x_{(p)}}{\sum_{p=1}^n x_{(p)}}.$$



Medidas de concentración

Coeficiente de Gini

- ▶ $G = 2F$.
- ▶ $F = \sum_{i=1}^n F_i - \frac{1}{2}$, con $F_i = \frac{(u_{i-1} + u_i)(v_i - v_{i-1})}{2}$.
- ▶ $G = 1 - \frac{1}{n} \sum_{i=1}^n (v_{i-1} + v_i)$.

